

RELATÓRIO TÉCNICO: ÉTICA, GOVERNANÇA E EQUIDADE EM VISÃO COMPUTACIONAL

1. Contextualização Ética e IA Responsável

A introdução de sistemas de Visão Computacional no diagnóstico médico exige uma governança de dados rigorosa (*Responsible AI*). Como os modelos baseados em Redes Neurais Convolucionais (CNNs) são altamente dependentes da representatividade e da distribuição dos dados de entrada, assimetrias demográficas ou clínicas podem fazer com que o algoritmo automatize e amplifique preconceitos em escala global. O objetivo desta auditoria é identificar os potenciais vieses presentes no pipeline do Cardiolo e estabelecer práticas estruturadas de mitigação para garantir um diagnóstico seguro, equitativo e transparente no ecossistema hospitalar.

2. Análise de Limitações e Vieses do Dataset

A auditoria técnica do pipeline identificou três limitações críticas com potencial de induzir o modelo a erros sistemáticos:

- Desbalanceamento de Classes (Viés Clínico):** O dataset reflete a escassez de dados do mundo real na saúde, apresentando 414 amostras Saudáveis contra apenas 30 de Cardiomegalia (menos de 5% do suporte de testes). Sem as devidas mitigações, esse cenário força a rede a se guiar pela classe majoritária, inflando artificialmente a acurácia global, mas mascarando o apagamento clínico da Cardiomegalia e do Infiltado, elevando o risco crítico de falsos negativos.
- Viés Demográfico e de Representatividade:** Variações anatômicas associadas ao gênero e à idade (como densidade do tecido mamário ou alterações senis na silhueta cardíaca) alteram a assinatura visual do Raio-X de Tórax. A sub-representação ou ausência de metadados estruturados desses grupos reduz a capacidade de generalização e de equidade da IA.
- Viés de Artefato (*Confounding Variables*):** Imagens obtidas por diferentes marcas de aparelhos radiológicos ou dispositivos portáteis de UTI trazem variações técnicas (como níveis de contraste, artefatos de posicionamento e marcas d'água de texto). A rede pode sofrer o fenômeno de *confounding*, associando erroneamente o ruído técnico do equipamento à presença de uma patologia, em vez de analisar puramente os padrões biológicos do tórax do paciente.

3. Métricas de Equidade (*Fairness Metrics*) Aplicadas

Par a garantir a paridade de desempenho entre diferentes subgrupos demográficos (\$G\$), monitora-se duas métricas formais durante o ciclo de validação do protótipo:

- Igualdade de Oportunidades (*Equal Opportunity*):** Garante que a taxa de Verdadeiros Positivos (TPR / Sensibilidade / *Recall*) seja equivalente para todos os grupos protegidos (ex: Homens e Mulheres), impedindo que o modelo seja menos sensível a doenças em um grupo específico.

$$P(\hat{Y} = 1 \mid G = \text{Homem}, Y = 1) = P(\hat{Y} = 1 \mid G = \text{Mulher}, Y = 1)$$

$$P(\hat{Y} = 1 \mid G = \text{Homem}) = P(\hat{Y} = 1 \mid G = \text{Mulher})$$

4. Plano de Mitigação e Governança do CardiolA

Para neutralizar os vieses identificados e alinhar o CardiolA com as diretrizes internacionais de governança em saúde, o plano de ação atua em três camadas complementares:

- **Pré-processamento:** Aplicação de técnicas de *Data Augmentation* controlado e balanceamento estatístico nas pastas de treino das classes minoritárias para equalizar o aprendizado dos lotes, associado ao corte padronizado (*cropping*) periférico para eliminar textos e artefatos de borda dos aparelhos.
- **Processamento:** Injeção da função `compute_class_weight` do Scikit-Learn diretamente no método `.fit()` do TensorFlow, combinada com a função de perda customizada *Focal Loss*. Essa abordagem eleva matematicamente o custo do erro nas patologias durante o *backpropagation*, forçando os gradientes da DenseNet121 a penalizarem severamente a negligência contra as classes de menor suporte. Nos testes práticos, isso evitou o colapso do modelo, garantindo saltos expressivos de *Recall* nas patologias (elevando Cardiomegalia para 0.47 e Infiltrado para 0.38).
- **Pós-processamento e Transparência:** Integração de mapas de ativação de classe por gradientes (**Grad-CAM**). O Grad-CAM gera uma sobreposição em mapa de calor (gama de cores) sobre a imagem médica original, revelando quais regiões anatômicas e texturas de pixels foram decisivas para o veredito da IA. Isso estabelece uma camada essencial de explicabilidade e permite a auditoria humana em tempo real pelo médico regulador.

5. Conclusão da Auditoria

Sob a perspectiva da governança de dados e ética médica, o projeto CardiolA cumpre as exigências de transparência ao documentar e expor com clareza as limitações de suas métricas internas. A escolha estratégica da arquitetura consolidada DenseNet121 reforça esse compromisso ético: suas conexões densas de reaproveitamento de características mitigaram o descompasso de domínio e preservaram o aprendizado das texturas patológicas complexas de forma consideravelmente mais justa e equilibrada que os blocos convolucionais simples desenvolvidos do zero, consolidando-se como um *baseline* altamente seguro, auditável e defensável para o ecossistema de saúde.